

Predição de Insuficiência Cardíaca via Rede Neural Multilayer Perceptron e Otimização por Grid Search

Antonio V. O. Borssato

Departamento de Informática – Universidade Federal do Espírito Santo (UFES)
Av. Fernando Ferrari, 514 – Goiabeiras – Vitória – ES – Brasil
CEP: 29075-910

(antonio.borssato@edu.ufes.br)

Abstract: *Heart failure (HF) is a multifactorial condition that affects the heart, where clinical and demographic analyses are essential for disease identification. With this in mind, this study aims to develop an artificial neural network model of the Multilayer Perceptron (MLP) type with Grid Search optimization, seeking a binary classification for HF patients using a clinical dataset containing variables such as age and blood pressure. The research is quantitative and qualitative, and the MLP method was chosen primarily for its ability to learn nonlinear relationships in tabular data.*

Resumo: *A insuficiência cardíaca (IC) é uma doença de condição multifatorial que atinge o coração, onde as análises clínicas e demográficas são essenciais para a identificação da doença. Pensando nisso, este trabalho tem como objetivo desenvolver um modelo de rede neural artificial do tipo Multilayer Perceptron (MLP) com otimização em Grid Search, buscando uma classificação binária para pacientes de IC, utilizando um conjunto de dados clínicos que contém variáveis como idade e pressão arterial. A pesquisa é quantitativa e qualitativa, e o método MLP foi escolhido principalmente pela sua capacidade de aprender relações não lineares em dados tabulares.*

1. Introdução

A insuficiência cardíaca (IC) é uma síndrome clínica que acontece com qualquer disfunção cardíaca estrutural ou funcional, que dificulta a ação do ventrículo em se preencher ou ejetar sangue [American Heart Association, 2005]. Em geral, o quadro clínico inclui a presença de dispnéia acompanhada de edema periférico e congestão pulmonar, mas também pode demonstrar sintomas como taquicardia, bolhas patológicas, sopros cardíacos e estase jugular [Santos e Bittencourt, 2008]. Sua complexidade clínica, associada a fatores de risco multifatoriais, exige métodos precisos e ágeis para identificação precoce de pacientes em risco, e por isso a análise de dados clínicos surge como uma ferramenta promissora, permitindo a extração de padrões ocultos que podem orientar decisões médicas mais assertivas.

Nesse contexto, uma rede neural artificial (RNA) do tipo *Multilayer Perceptron* (MLP) pode se mostrar uma ferramenta prática para a classificação dos casos clínicos de IC. RNAs desse tipo são sistemas paralelos distribuídos, compostos por camadas pequenas de perceptrons, onde cada um contém funções de ativação específica se baseando em uma forma de aprendizagem supervisionada, onde o erro dessas análises deve ser minimizado constantemente via algoritmos *Backpropagation*. [Lima et.al., 2016]. Alinhado ao MLP, o Grid Search é um método que se baseia na varredura exaustiva dos parâmetros de interesse, onde passos menores requerem mais interações para a varredura completa dos dados. [Pipa, Melo e Vieira, 2017]

Pensando nisso, o principal objetivo deste trabalho é desenvolver um modelo de RNA do tipo MLP com otimização em *Grid Search* para classificação binária de pacientes com risco de insuficiência cardíaca, utilizando um conjunto de dados clínicos que inclui variáveis como idade, pressão arterial, colesterol e indicadores de eletrocardiograma. A escolha do MLP justifica-se pela sua capacidade de aprender relações não lineares em dados tabulares, adaptando-se às especificidades de problemas médicos, onde a interpretação de múltiplas variáveis inter-relacionadas é crítica.

2. Definição do Problema

Classificação binária (presença ou ausência de insuficiência cardíaca).

A IC se mostra como uma condição multifatorial, onde as análises clínicas e demográficas auxiliam na identificação precoce da doença. Modelos tradicionais de aprendizado de máquina, como a regressão logística e *Random Forest*, são amplamente utilizados para essa tarefa, porém sua eficácia em capturar relações não lineares complexas entre variáveis clínicas pode ser limitada. Nesse cenário, propõe-se investigar o potencial de RNAs, especificamente uma arquitetura MLP, na classificação binária de pacientes com risco de insuficiência cardíaca. Para isso, este trabalho busca resolver as seguintes questões: qual a precisão, *recall* e *F1-Score* do modelo MLP na predição de risco de insuficiência cardíaca com otimização por *Grid Search*; quais variáveis clínicas têm maior impacto nas predições do modelo; e quais as limitações do modelo.

3. Descrição do Conjunto de dados

Os dados foram coletados através do Kaggle. Trata-se de uma plataforma online criada em 2010 para hospedar competições de ciência de dados [Vassalo, 2021], e também agrupa diversos tipos de banco de dados para análise.

As principais variáveis são numéricas (*Age*, *RestingBP*, *Cholesterol*, *MaxHR*, *Oldpeak*), categóricas (*Sex*, *ChestPainType*, *FastingBS*, *RestingECG*, *ExerciseAngina*, *ST_Slope*) e *target* (*Heart Disease* - binário: 0 ou 1).

4. Metodologia

A metodologia deste trabalho foi dividida em três etapas fundamentais: coleta e pré-processamento de dados; análise descritiva e exploratória de dados; aplicação da Rede Neural com *Grid Search*.

4.1. Coleta e pré-processamento

Na etapa de coleta e pré-processamento, o conjunto de dados Heart Failure Prediction foi obtido do Kaggle, contendo 918 registros clínicos de pacientes. Inicialmente, verificou-se a ausência de valores ausentes, garantindo a integridade dos dados. Em seguida, foi avaliada a remoção dos registros com valores improváveis, como 0 batimentos em repouso. Para tratar variáveis categóricas como *Sex*, *ChestPainType* e *ST_Slope*, aplicou-se a técnica de One-Hot Encoding nas variáveis com mais de duas categorias, convertendo-as em representações numéricas binárias. As variáveis com duas categorias foram convertidas usando Label Encoder, também para valores binários. Posteriormente, os dados foram separados em conjunto de treino e test, e normalizados com Standar Scaler.

4.2. Análise descritiva e exploratória de dados

Na fase de análise descritiva e exploratória de dados, foram calculadas estatísticas descritivas (média, desvio padrão, quartis) para compreender as características e a distribuição dos dados, e realizada uma análise de correlação (através de matriz de correlação e pairplots) para identificar as relações entre as variáveis numéricas. Também foram observadas as distribuições das variáveis categóricas e do target.

4.3. Aplicação da Rede Neural com Grid Search.

Na etapa final de aplicação da rede neural com *Grid Search*, implementou-se uma arquitetura *Multilayer Perceptron* (MLP) com um espaço de buscas para otimizar hiperparâmetros críticos, como taxa de aprendizado, número de épocas, número de neurônios por camada oculta, número de camadas ocultas, otimizador e tamanho do batch. O modelo foi treinado com *Early Stopping* para interromper o treinamento caso não houvesse melhoria na validação após 5 épocas. As métricas de avaliação incluíram precisão, recall e *F1-Score*, além da matriz de confusão, com validação cruzada *K-Fold* (k=3) para garantir robustez, que foram analisados nos resultados.

A arquitetura da rede MLP foi definida com uma camada de entrada contendo um número de neurônios igual ao número de features do conjunto de dados e ativação ReLU. Foram adicionadas de forma dinâmica múltiplas camadas ocultas, variando conforme os hiperparâmetros do *Grid Search*, e ativação ReLU, normalização em batch (*Batch Normalization*) e dropout de 20% para evitar *overfitting*. A camada de saída possui um único neurônio com ativação sigmoide para classificação binária. O modelo foi compilado utilizando a função de perda *binary_crossentropy* do keras e diferentes otimizadores (Adam ou RMSprop), ajustados com *clipping* para estabilidade no treinamento. Além disso, a métrica *F1-Score* foi utilizada para otimizar o desempenho da rede na predição de insuficiência cardíaca.

As variações do *Grid Search* foram:

Taxa de aprendizado (*learn_rate*): 0.001, 0.01

Número de neurônios nas camadas ocultas (*neurons_ocultos*): igual ao número de features do conjunto de teste (*X_test_scaled.shape[1]*) ou o dobro do número de features (*X_test_scaled.shape[1] * 2*)

Otimizador: Adam, RMSprop

Número de camadas ocultas (*num_camadas_ocultas*): 1, 2, 3

Número de épocas (*epochs*): 30, 60

Tamanho do batch (*batch_size*): 32, 64

5. Resultados

A melhor combinação de hiperparâmetros foi:

batch_size: 64, **epochs:** 60, **learn_rate:** 0.01, **neurons_ocultos:** 15, **num_camadas_ocultas:** 2 e **otimizador:** RMSprop

Os resultados obtidos a partir do treinamento da melhor arquitetura de MLP encontrada pelo Grid Search com KerasClassifier encontra-se abaixo:

	precision	recall	f1-score	support
Sem Doença	0.90	0.80	0.85	117
Com Doença	0.81	0.90	0.85	107
accuracy			0.85	224
macro avg	0.85	0.85	0.85	224
weighted avg	0.85	0.85	0.85	224

Figura 1: classification report do modelo nos dados de teste.




Figura 2: matriz de confusão do modelo nos dados de teste.




Figura 3: evolução do treinamento em cada combinação de hiperparâmetros do Grid Search

6. Discussões

Os resultados da predição de insuficiência cardíaca por rede neural MLP foram satisfatórios para esses conjuntos de dados. Percebe-se que a escolha dos hiperparâmetros por

meio de grid search resultou em um modelo que desempenhou bem quando se observa, por exemplo, a matriz de confusão e o *classification report*, visto que há um bom equilíbrio entre precisão e revocação.

Entretanto, considerando que problemas médicos precisam "que o modelo acerte quando precisa acertar", ou seja, a presença de falsos negativos pode ser um problema no diagnóstico de pacientes.

Abaixo serão respondidas as perguntas propostas na descrição do problema.

6.1. Qual a precisão, recall e F1-Score do modelo MLP na predição de risco de insuficiência cardíaca com otimização por Grid Search?

O classification report apresentou os seguintes resultados:

Precisão (Precision): Sem Doença: 0.88 | Com Doença: 0.82

Média Macro: 0.85 | Média Ponderada: 0.85

Recall (Sensibilidade): Sem Doença: 0.83 | Com Doença: 0.88

Média Macro: 0.85 | Média Ponderada: 0.85

F1-Score: Sem Doença: 0.85 | Com Doença: 0.85

Média Macro: 0.85 | Média Ponderada: 0.85

A matriz de confusão mostra que o modelo obteve alta taxa de acerto geral, com 94 acertos para pacientes com insuficiência cardíaca e 97 acertos para pacientes sem a condição. No entanto, ainda foram observados 13 falsos positivos e 20 falsos negativos, o que pode ser crítico em um contexto clínico, pois pacientes com insuficiência cardíaca podem não ser diagnosticados corretamente.

6.2. Quais variáveis clínicas têm maior impacto nas predições do modelo?




Figura 4: gráfico *BeeSwarm* de valores *Shap*

A análise do gráfico Beeswarm dos valores SHAP revela as variáveis clínicas com maior impacto nas previsões do modelo. As variáveis ST_Slope_Flat, Sex, ChestPainType_ATA, ExerciseAngina e ChestPainType_NAP apresentam os 5 maiores valores absolutos de SHAP, indicando forte influência na decisão do modelo.

ST_Slope_Flat: Valores altos tendem a aumentar a probabilidade de insuficiência cardíaca, enquanto valores baixos diminuem a probabilidade de insuficiência.

Sex: Valores mais altos (indicando indivíduos do sexo masculino) tendem a aumentar a probabilidade de insuficiência cardíaca, enquanto valores mais baixos (indicando indivíduos do sexo feminino) tendem a reduzir a probabilidade de insuficiência.

ChestPainType_ATA: Valores altos tendem a reduzir a probabilidade de insuficiência cardíaca, enquanto valores baixos aumentam a probabilidade de insuficiência.

ExerciseAngina: Valores altos da dor no peito ao se exercitar tendem a aumentar a probabilidade de insuficiência cardíaca, enquanto valores baixos diminuem a probabilidade de insuficiência.

ChestPainType_NAP: Valores altos tendem a reduzir a probabilidade de insuficiência cardíaca, enquanto valores baixos aumentam a probabilidade de insuficiência.

Outras variáveis, como ST_Slope_up, RestingECG_Normal, Age e Oldpeak, apresentam influência menor, mas ainda relevante. Valores altos de ST_Slope_up tendem a reduzir a probabilidade de insuficiência cardíaca, enquanto valores baixos aumentam a probabilidade. Além disso, o eletrocardiograma de repouso (ECG) é um fator importante, com um ECG normal reduzindo a probabilidade de insuficiência cardíaca, enquanto padrões anormais aumentam o risco. A idade dos pacientes e o valor de Oldpeak, que é um indicador de depressão do segmento ST, também têm impacto significativo, sendo que valores elevados de Oldpeak e idade estão associados a uma maior probabilidade de insuficiência cardíaca.

Portanto, pacientes do sexo masculino que apresentam dores no peito após o exercício e ST_Slope_Flat elevado, combinados com alta incidência de ChestPainType_ATA e ChestPainType_NAP, configuram um perfil de risco elevado. Esse risco é ainda ampliado em indivíduos com ST_Slope_UP reduzido, ECG anormal, idade avançada e valores elevados de Oldpeak, sugerindo comprometimento cardiovascular significativo. análise do gráfico Beeswarm dos valores SHAP revela as variáveis clínicas com maior impacto nas previsões do modelo.

7. Conclusões

Em resumo, o modelo MLP otimizado por grid search demonstrou desempenho satisfatório, equilibrando precisão e recall, embora os 23 falsos negativos evidenciem riscos críticos em um cenário clínico, onde erros podem comprometer a identificação e tratamento adequado dos pacientes.

A análise dos valores SHAP destacou que variáveis como ST_Slope_Flat, Sex, ChestPainType_ATA, ExerciseAngina e ChestPainType_NAP exercem forte influência na previsão, permitindo identificar um perfil de alto risco, especialmente entre indivíduos do sexo masculino que apresentam sinais clínicos adversos, como angina induzida por esforço, ECG anormal, idade avançada e valores elevados de Oldpeak.

Apesar dos resultados positivos gerais, as limitações computacionais no espaço de busca dos hiperparâmetros sugerem que novas otimizações podem ser exploradas para aprimorar ainda mais o modelo e reduzir os potenciais riscos de falsos negativos.

8. Referências

- Hunt, S. A., Abraham, W. T., Chin, M. H., Feldman, A. M., Francis, G. S., Ganiats, T. G., et al. (2005). "ACC/AHA 2005 Guideline Update for the Diagnosis and Management of Chronic Heart Failure in the Adult: A Report of the American College of Cardiology/American Heart Association Task Force on Practice Guidelines (Writing Committee to Update the 2001 Guidelines for the Evaluation and Management of Heart Failure)." American College of Cardiology web site. Disponível em: <http://www.acc.org/clinical/guidelines/failure/index.pdf>. Circulation, 112, e154-e235.
- Santos, I. S. e Bittencourt, M. S. (2008). "Insuficiência cardíaca." Revista de Medicina de São Paulo, 87(4), 224-231. Disponível em: <https://pesquisa.bvsalud.org/portal/resource/pt/lil-524386>.
- Lima, M. A., Ferreira, G. G., Oliveira, L. L. C., Diniz, R. F. S., & Ferreira, C. B. (2016). "Uso de Redes Neurais Artificiais (RNA) do tipo Multilayer Perceptrons (MLP) modificado com processamento estatístico em paralelo para estudo do problema de classificação da origem de vinho tinto." Revista Brasileira de Agropecuária Sustentável, 6(2).
- Pipa, D., Mello, A. J. T. S., & Vieira, L. (2017). "Nova Técnica de Centroide para Sensores de Frente de Onda com Ponto Elongado Usando Grid Search". Anais do Congresso Brasileiro de Engenharia Mecânica (COBEM). Disponível em: <https://www.sbrt.org.br/sbrt2017/anais/1570361640.pdf>
- Vassalo, D. H. C. (2023) "Análises de competições presentes na Plataforma Kaggle para auxiliar no desenvolvimento de novas soluções para problemas de visão computacional." Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) - Instituto de Computação, Universidade Federal de Alagoas, Maceió, 2021.

9. Trabalhos relacionados

- Rodrigues, T. B. "Seleção de variáveis e classificação de padrões por redes neurais como auxílio ao diagnóstico de doença cardíaca." 2006. Dissertação (Mestrado em Engenharia) – Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, 2006. de Mestrado). Pontifícia Universidade Católica do Rio de Janeiro, Rio de Janeiro, Brasil.
- Firmino, J. V. L. C. "Desenvolvimento de um sistema para identificação de padrão sonoro da voz humana de indivíduos com insuficiência cardíaca utilizando redes neurais artificiais." 2021. Dissertação (Mestrado em Engenharia Elétrica) – Universidade Federal da Paraíba, João Pessoa, 2021. Disponível em: <https://repositorio.ufpb.br/jspui/handle/123456789/24500>. Acesso em 18 mar. de 2025.
- Ogunsanya, M.; Isichei, J.; Desai, S. "Grid search hyperparameter tuning in additive manufacturing processes." *Manufacturing Letters*, v. 35, p. 1031-1042, 2023. Disponível em: https://www.sciencedirect.com/science/article/pii/S221384632300113X?utm_source=chatgpt.com Acesso em: 18 mar. 2025.